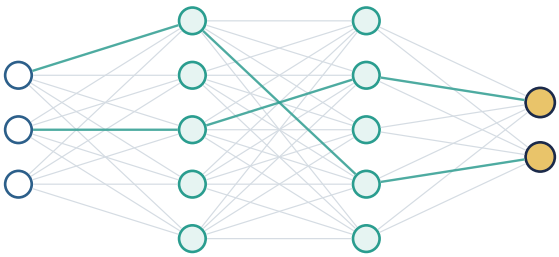
دانشگاه فردوسی مشهد | گروه مهندسی کامپیوتر

هوش محاسباتی Computational Intelligence

پروژهٔ خوشه‌بندی

خوشه‌بندی زلزله‌های جهان



مدرس:	دکتر احسان فضل‌ارثی
مسئولان پروژه:	رضا فراستی، نیایش اعظمی
آیدی در تلگرام:	@Rezafarasati4 @nia_azm
مهلت تحویل اول:	دوشنبه ۲۵ آبان ۱۴۰۵
مهلت تحویل نهایی:	شنبه ۳۰ آبان ۱۴۰۵

دستورالعمل‌ها

این پروژه در دو مرحله تحویل داده می‌شود. لطفاً پیش از شروع، ترتیب مراحل را بخوانید؛ بخش پیش‌بینی باید **پیش از اجرای الگوریتم‌های خوشه‌بندی** تکمیل و ثبت شود.

- **تحویل اول (مهلت: دوشنبه ۲۵ آبان ۱۴۰۵):** گزارش فاز ۱ شامل نقشه، سه ناحیهٔ انتخابی، تحلیل چگالی و پیش‌بینی‌های P1 تا P4 با استدلال و معیار رد، به صورت یک فایل PDF با حداکثر ۵ صفحه، به همراه Notebook اجراشده.
- **تحویل نهایی (مهلت: شنبه ۳۰ آبان ۱۴۰۵):** گزارش فازهای ۲ تا ۴، جدول بازبینی پیش‌بینی‌ها و توصیهٔ نهایی، به صورت یک فایل PDF با حداکثر ۱۲ صفحه، همراه با یک Notebook اجراشده و قابل بازتولید. پاسخ هر سؤال امتیازیِ انجام‌شده را می‌توان در پیوست گزارش (حداکثر ۲ صفحه برای هر سؤال، خارج از محدودیت ۱۲ صفحه) آورد. **همهٔ اعداد و نمودارهای گزارش باید از نوت‌بوک قابل بازتولید باشند.**
- پروژه به‌صورت **گروه‌های دو نفره** انجام می‌شود. **نام هر دو عضو** باید هم در گزارش (صفحهٔ اول) و هم در Notebook نوشته شود. فایل نهایی را فقط در **سامانهٔ آموزش مجازی دانشگاه (VU)** بارگذاری کنید؛ بارگذاری توسط **یک نفر از اعضای گروه** کافی است.
- فایل تحویلی یک فایل ZIP است. نام آن باید شمارهٔ دانشجویی **هر دو عضو** را داشته باشد:

`StudentID1-StudentID2-Clustering.zip`

برای مثال `4021234567-4027654321-Clustering.zip`.

- استفاده از کتابخانه‌های آمادهٔ Python و ابزارهای هوش مصنوعی مجاز است. نیازی به پیاده‌سازی الگوریتم‌ها از صفر نیست؛ بااین‌حال باید بتوانید تمام انتخاب‌ها، نمودارها و نتیجه‌گیری‌های خود را توضیح دهید. در انتهای گزارش، کاربرد ابزارهای هوش مصنوعی را در چند خط ذکر کنید.
- هر دانشجو در طول ترم در مجموع **۵ روز مهلت ارسال با تأخیر** دارد که می‌تواند از آن برای پروژه‌ها استفاده کند. مهلت‌ها تمدید نمی‌شوند؛ تحویل پس از موعد فقط تا سقف روزهای تأخیر باقی‌ماندهٔ شما امکان‌پذیر است و از آن کسر می‌شود. **هر تأخیری، حتی کمتر از یک روز، یک روز کامل حساب می‌شود**؛ برای مثال اگر پروژه را ۱۲ ساعت دیر بفرستید، یک روز از مهلت تأخیر شما کم می‌شود.
- **کپی‌برداری از پاسخ یا گزارش دیگران و ارائهٔ آن به نام خود، تقلب محسوب می‌شود.** استفاده از ابزارهای هوش مصنوعی طبق بند بالا مجاز است؛ اما هر دانشجو مسئول تحلیل‌ها و نتایج گزارش خود است.
- **پیش‌بینی اشتباه به‌خودی‌خود باعث کسر نمره نمی‌شود.** نمره به استدلال اولیه، شواهد آزمایش و بررسی دقیق اختلاف پیش‌بینی با نتیجه تعلق می‌گیرد.
- رسم نمودار بدون توضیح آن، یا نوشتن توضیح کلی بدون ارجاع به دادهٔ همین پروژه، پاسخ کامل محسوب نمی‌شود.

معرفی پروژه

تصور کنید نقشهٔ زمین را با محل وقوع هزاران زلزله علامت زده‌ایم. زلزله‌ها در همه‌جای جهان یکسان پخش نشده‌اند: برخی مناطق بسیار متراکم‌اند، برخی نقاط در امتداد کمربندهای کشیده قرار گرفته‌اند و برخی زلزله‌ها از بقیه دورافتاده‌اند.

در این پروژه قرار است با یک **دیتاست واقعی از زلزله‌های جهان** بررسی کنید که الگوریتم‌های K-Means، DBSCAN و خوشه‌بندی سلسله‌مراتبی از این الگوها چه برداشتی دارند. هدف این نیست که صرفاً چند الگوریتم را اجرا و بهترین عدد را گزارش کنید؛ باید **ابتدا پیش‌بینی، سپس آزمایش و در پایان تحلیل** کنید.

دو هدف متفاوت از خوشه‌بندی

قرار است نتایج را از دید دو کاربرد بررسی کنید:

دو سناریو

- **سناریوی الف ـ منطقه‌بندی:** یک سازمان می‌خواهد زلزله‌های ثبت‌شده را به حدود ۱۰ تا ۲۰ منطقهٔ قابل توصیف تقسیم کند. هر زلزله باید به یک منطقه اختصاص داده شود و مناطق تا حد ممکن از نظر جغرافیایی منسجم باشند.
- **سناریوی ب ـ کشف ساختار:** یک پژوهشگر می‌خواهد کمربندها و تجمع‌های لرزه‌خیز را بدون تعیین تعداد خوشه‌ها از قبل پیدا کند. در این کاربرد، جدا ماندن برخی نقاط به‌عنوان نویز قابل قبول است.

یک خروجی ممکن است برای سناریوی الف مناسب و برای سناریوی ب نامناسب باشد. بنابراین هر جا می‌گویید یک خوشه‌بندی «بهتر» است، مشخص کنید **برای کدام هدف** و **با چه شواهدی**.

دیتاست و نمایش پیش‌فرض

از دیتاست Significant Earthquakes, 1965–2016 استفاده کنید:

https://www.kaggle.com/datasets/usgs/earthquake-database

تنها رکوردهایی را نگه دارید که مقدار ستون Type آن‌ها Earthquake است. برای خوشه‌بندی اصلی فقط از موقعیت جغرافیایی (Latitude و Longitude) استفاده می‌کنیم؛ ستون‌های Depth و Magnitude را فقط برای توصیف داده می‌توانید بررسی کنید.

چگالی، خطر لرزه‌ای نیست

چگالی رویدادهای ثبت‌شده در این دیتاست، معادل خطر لرزه‌ای واقعی یک منطقه نیست؛ هدف، تحلیل الگوی مکانی دادهٔ موجود است، نه پیش‌بینی زلزله.

طول و عرض جغرافیایی زاویه‌اند و به‌طور مستقیم مختصات مناسبی برای فاصلهٔ اقلیدسی نیستند. به همین دلیل، مگر در آزمایشی که صریحاً خلاف آن خواسته شده، از تبدیل زیر به مختصات سه‌بعدی روی کرهٔ واحد استفاده کنید:

مختصات و فاصله

اگر φ عرض جغرافیایی و λ طول جغرافیایی (برحسب رادیان) باشند،

$$x = \cos\varphi\cos\lambda, \qquad y = \cos\varphi\sin\lambda, \qquad z = \sin\varphi.$$

اگر فاصلهٔ وتری دو نقطه روی کرهٔ واحد برابر c باشد، فاصلهٔ متناظر روی سطح زمین d، با شعاع زمین $R = 6371\,\mathrm{km}$، از رابطهٔ زیر به دست می‌آید:

$$d = 2R\arcsin\left(\frac{c}{2}\right), \qquad c = 2\sin\left(\frac{d}{2R}\right).$$

پس برای استفاده از ε برحسب کیلومتر در DBSCAN، آن را با فرمول دوم به شعاع وتری تبدیل کنید. در گزارش، پارامترهای فاصله‌ای را **برحسب کیلومتر** بیان کنید.

قواعد مشترک آزمایش‌ها

- سه رقم آخر شمارهٔ دانشجویی را seed پایهٔ s بگیرید. برای نمونه‌گیری و اجرای تصادفی از s استفاده کنید؛ هرجا اجرای دوم با seed متفاوت خواسته شده، از $s+1$ استفاده کنید.
- یک بار از دادهٔ پاک‌سازی‌شده، **۲۰۰۰ نقطه** را به‌طور تصادفی با seed پایه انتخاب کنید و این نمونه را S بنامید. خوشه‌بندی سلسله‌مراتبی فقط روی S انجام می‌شود. در مقایسهٔ نهایی، برچسب‌های نقاط S از خروجی روش‌هایی که روی دادهٔ کامل اجرا شده‌اند استخراج می‌شوند.
- برای نمایش خوشه‌ها می‌توانید از نقشه یا نمودار طول و عرض جغرافیایی استفاده کنید. عنوان هر شکل باید الگوریتم و پارامترهای آن را مشخص کند؛ نقاط نویز را جدا نمایش دهید.

دو معیار موردنیاز

ARI: میزان توافق دو دسته‌بندی از **همان نقاط** را می‌سنجد؛ مقدار ۱ یعنی توافق کامل و مقدار نزدیک به صفر معمولاً یعنی توافق در حد تصادف. نام یا شمارهٔ خوشه‌ها اهمیتی ندارد. تابع آماده: `adjusted_rand_score`.

Silhouette: بررسی می‌کند نقاط یک خوشه چقدر به یکدیگر نزدیک و از خوشه‌های دیگر دورند. مقدار بالاتر معمولاً نشان‌دهندهٔ خوشه‌های فشرده‌تر و جداشده‌تر است، نه الزاماً خوشه‌بندی مناسب‌تر برای کاربرد ما. تابع آماده: `silhouette_score`. این معیار در حالت عادی دست‌کم به دو خوشه نیاز دارد.

فاز ۱: شناخت داده و پیش‌بینی

۲۰ نمره

زمان تحویل

این فاز باید پیش از اجرای هر الگوریتم خوشه‌بندی تحویل داده شود. می‌توانید نمودارهای دادهٔ خام و آمارهای مقدماتی را محاسبه کنید؛ اما خروجی خوشه‌بندی‌ها را نبینید.

پرسش آ

نقشه

پس از حذف رویدادهای غیرزلزله، تعداد نمونه‌ها را اعلام کنید و محل زلزله‌ها را روی یک نقشهٔ جهان نمایش دهید.

با مشاهدهٔ نقشه، سه ناحیهٔ نمونه با الگوهای مکانی متفاوت انتخاب کنید؛ تلاش کنید دست‌کم یک ناحیهٔ نسبتاً متراکم و یک ناحیهٔ نسبتاً کم‌تراکم در انتخاب‌هایتان باشد. محدودهٔ هر ناحیه را روی نقشه مشخص کنید و در جدولی بازهٔ مختصات، تعداد زلزله‌ها و دلیل انتخاب آن را بنویسید. برای هر ناحیه توضیح دهید پراکندگی نقاط بیشتر فشرده، کشیده، چندبخشی یا پراکنده به نظر می‌رسد. تراکم مورد انتظار در این مرحله صرفاً یک برداشت اولیه از نقشه است و باید در پرسش بعدی با عدد بررسی شود. انتخاب شما باید بر اساس دادهٔ خام و پیش از اجرای الگوریتم‌ها باشد.

پرسش ب

چگالی

برای هر زلزله، فاصلهٔ آن تا **دهمین همسایهٔ نزدیک، بدون شمارش خود نقطه** را برحسب کیلومتر محاسبه کنید. مقدار کوچک‌تر معمولاً نشانهٔ تراکم بیشتر اطراف نقطه است. توزیع این فاصله‌ها را در یک هیستوگرام نشان دهید. سپس برای هر یک از سه ناحیه‌ای که خودتان انتخاب کرده‌اید، تعداد زلزله‌ها و **چارک اول، میانه و چارک سوم** این فاصله را در یک جدول بیاورید. آیا تفاوت عددها با برداشت بصری شما از نقشه سازگار است؟ آیا یک شعاع همسایگی ثابت برای همهٔ نواحی مناسب به نظر می‌رسد؟ چرا؟

پرسش پ

فاصله

توضیح دهید چرا محاسبهٔ مستقیم فاصلهٔ اقلیدسی روی دو ستون Latitude و Longitude می‌تواند گمراه‌کننده باشد. یک مثال جغرافیایی روشن بزنید؛ مثلاً دو نقطه در دو سوی نصف‌النهار 180°. توضیح دهید نمایش سه‌بعدی بالا چه مشکلی را برطرف می‌کند.

پرسش ت

پیش‌بینی

پیش از اجرا چهار پیش‌بینی زیر را ثبت کنید. برای هر مورد، سه چیز بنویسید: **چه اتفاقی انتظار دارید بیفتد؟ چرا؟ چه نتیجه‌ای پیش‌بینی شما را رد می‌کند؟**

P1. اگر K-Means را با $k = 12$ اجرا کنید، کدام ساختار مکانیِ کشیده یا گسترده ممکن است بین چند خوشه تقسیم شود؟ دلیل شما چیست؟

P2. در DBSCAN، با افزایش ε از مقدار کوچک به بزرگ، انتظار دارید درصد نقاط نویز و اندازهٔ بزرگ‌ترین خوشه چگونه تغییر کند؟ آیا مقداری از ε وجود دارد که هم نواحی با تراکم بالاتر و هم نواحی با تراکم پایین‌تر را خوب خوشه‌بندی کند؟

P3. اگر Single Link و Average Link هرکدام ۱۲ خوشه بسازند، کدام یک بیشتر مستعد تشکیل یک خوشهٔ بسیار بزرگ و چند خوشهٔ کوچک است؟ چرا؟

P4. برای سناریوی الف و ب، فعلاً کدام الگوریتم را مناسب‌تر می‌دانید؟ این انتخاب را با فرض‌های الگوریتم و شواهد داده توجیه کنید.

فاز ۲: بررسی K-Means

۲۵ نمره

در این فاز ببینید الگوریتمی که هر نقطه را به نزدیک‌ترین مرکز نسبت می‌دهد، با داده‌ای دارای کمربندهای طولانی چگونه رفتار می‌کند.

پرسش آ

نمایش

K-Means را با $k = 12$ و `n_init=10` یک بار روی طول و عرض جغرافیاییِ خام و یک بار روی مختصات سه‌بعدی کرهٔ واحد اجرا کنید (هر دو با seed برابر s). نقشهٔ دو خروجی را رسم کنید و با معیار Adjusted Rand Index (ARI) میزان توافق برچسب‌های آن‌ها را بسنجید. یک تفاوت مشخص روی نقشه پیدا کنید و توضیح دهید چرا نحوهٔ نمایش موقعیت می‌تواند چنین اثری داشته باشد.

برای سنجش تغییرپذیری ناشی از مقداردهی اولیه، K-Means سه‌بعدی را با همان پارامترها و این بار با seed برابر $s + 1$ اجرا کنید. ARI بین دو اجرای سه‌بعدی را به‌عنوان **خط پایه** گزارش دهید. آیا اختلاف خروجی دوبعدی و سه‌بعدی از اختلاف مشاهده‌شده بین این دو اجرای سه‌بعدی بیشتر است؟ این مقایسه تا چه حد از توضیح شما دربارهٔ اثر نمایش داده پشتیبانی می‌کند؟ **توجه کنید که این خط پایه، سهم دقیق هر عامل را جدا نمی‌کند.**

پرسش ب

انتخاب k

برای $k \in \{8, 12, 16, 20\}$، روی نمایش سه‌بعدی، الگوریتم را با `n_init=10` اجرا کنید. نمودار inertia (مجموع مربعات فاصله تا مراکز) را رسم کنید. همچنین برای هر خروجی، Silhouette را تنها روی نقاط نمونهٔ S حساب کنید. با توجه به این شواهد و هدف **سناریوی الف**، مقدار k نهایی خود را انتخاب و توجیه کنید. اگر این دو معیار پیشنهاد روشنی ندارند، همین را با دلیل بیان کنید.

پرسش پ تحلیل

خروجی منتخب را بررسی کنید. یک مثال از **تقسیم یک منطقهٔ لرزه‌خیز بین چند خوشه** یا **قرار گرفتن مناطق جدا از هم در یک خوشه** نشان دهید. با توجه به مرزهای تصمیم K-Means توضیح دهید چرا این اتفاق رخ داده است. سپس به پیش‌بینی P1 برگردید: کدام بخش آن درست بود و کدام بخش نیاز به اصلاح دارد؟ آیا این رفتار برای سناریوی الف الزاماً بد است؟

پرسش ت گستره

برای هر خوشهٔ خروجی منتخب، **گسترهٔ جغرافیایی** آن را حساب کنید: بیشترین فاصلهٔ روی سطح زمین بین دو زلزلهٔ همان خوشه، برحسب کیلومتر. (برای خوشه‌های بزرگ می‌توانید از یک زیرنمونهٔ تصادفی، مثلاً ۱۵۰۰ نقطه، استفاده کنید؛ در این صورت مقدار به‌دست‌آمده را **برآوردی از پایین برای بیشترین فاصله** بنامید و اندازهٔ زیرنمونه را ذکر کنید.) آیا این مناطق از نظر اندازه برای سناریوی الف قابل قبول‌اند؟ با یک خوشهٔ مشخص توضیح دهید. اگر قابل قبول نیستند، چه چیزی را تغییر می‌دهید: k، الگوریتم، یا انتظار سناریو؟ چرا؟

فاز ۳: DBSCAN و خوشه‌بندی سلسله‌مراتبی

۳۰ نمره

در این فاز می‌خواهیم ببینیم روش‌های مبتنی بر چگالی و اتصال نقاط، چه ساختارهایی پیدا می‌کنند که K-Means ممکن است نبیند.

پرسش آ DBSCAN

DBSCAN را روی دادهٔ کامل، با `min_samples=10` و $\varepsilon \in \{75, 200, 500\}\,\mathrm{km}$ اجرا کنید. برای هر مقدار، **تعداد خوشه‌ها، درصد نویز، اندازهٔ بزرگ‌ترین خوشه (تعداد نقاط و سهم آن از کل نقاط) و تعداد خوشه‌های بسیار کوچک** را در یک جدول ثبت کنید. در این پروژه، خوشهٔ بسیار کوچک خوشه‌ای با کمتر از ۲۰ نقطه تعریف می‌شود؛ بنابراین تعداد خوشه‌های دارای ۱۰ تا ۱۹ نقطه را گزارش کنید. نقشهٔ دو حالت را که تفاوت آموزنده‌تری دارند رسم کنید. تغییرات را با سازوکار نقاط هسته‌ای (core points) و گسترش خوشه‌ها توضیح دهید و نتیجه را با P2 مقایسه کنید.

یک نکتهٔ کوچک دربارهٔ min_samples

در `min_samples` scikit-learn **خود نقطه را هم می‌شمارد**. پس فاصلهٔ فاز ۱ (پرسش ب)، یعنی دهمین همسایه بدون خود نقطه، دقیقاً با `min_samples=11` متناظر است. این اختلاف یک‌همسایه‌ای در این پروژه اهمیتی ندارد؛ همه‌جا `min_samples=10` را به کار ببرید.

پرسش ب

چگالی

برای هر یک از سه مقدار ε و هر یک از سه ناحیه‌ای که در فاز ۱ انتخاب کرده‌اید، این سه مورد را در یک جدول بنویسید:

(۱) درصد زلزله‌های منطقه که **نویز** شده‌اند؛

(۲) درصد زلزله‌های منطقه که در **خوشهٔ اصلی** آن هستند (خوشهٔ اصلی = خوشه‌ای که بیشترین تعداد زلزله‌های آن منطقه را دارد)؛

(۳) آیا خوشهٔ اصلی این ناحیه **با خوشهٔ اصلی ناحیهٔ دیگری** از جدول مشترک است؟ اگر بله، نام ناحیهٔ دیگر را بنویسید (یعنی نقاط دو ناحیه در یک خوشه قرار گرفته‌اند).

سپس پاسخ دهید: آیا در بین مقادیر آزمایش‌شده، تنظیمی پیدا می‌کنید که **ساختارهای مکانی متفاوتی را که در فاز ۱ انتخاب کرده‌اید** به شکلی قابل قبول از هم جدا کند و همزمان بخش بزرگی از نقاط را نویز نکند؟ پیش از پاسخ، معیار خود برای «خوب» را با عدد بنویسید (مثلاً «نویز هر منطقه کمتر از ٪۳۰»). اگر چنین تنظیمی پیدا نکردید، محدودیت مشاهده‌شده را با شواهد همین جدول و فاصله‌های همسایگی فاز ۱ (پرسش ب) توضیح دهید. در پایان، **یک مقدار** ε برای سناریوی ب انتخاب و دلیلش را بنویسید.

پرسش پ

سلسله‌مراتبی

فقط روی نمونهٔ مشترک S، خوشه‌بندی سلسله‌مراتبی را با Single Link و Average Link انجام دهید و هر دو درخت را در **۱۲ خوشه** برش بزنید. نقشهٔ خروجی‌ها و جدول اندازهٔ خوشه‌ها را ارائه کنید. آیا یک روش خوشه‌های نامتوازن‌تر تولید کرده است؟ نتیجه را با P3 مقایسه کنید.

پرسش ت

اثر زنجیره‌ای

اگر Single Link گروه‌های دور یا کم‌تراکم را با زنجیره‌ای از نقاط به هم متصل کرده است، **یک نمونهٔ مشخص** روی نقشه نشان دهید. با تعریف Single Link علت آن را توضیح دهید و بگویید چرا Average Link ممکن است نتیجهٔ متفاوتی بدهد. این اتصال برای **سناریوی الف** و **سناریوی ب** چه مزیت یا ایرادی دارد؟

فاز ۴: ارزیابی و نتیجه‌گیری

۲۵ نمره

پرسش آ ارزیابی

برای مقایسهٔ خروجی‌ها روی نقاط یکسان، نتایج منتخب K-Means و DBSCAN را که در فازهای ۲ و ۳ روی **دادهٔ کامل** به دست آورده‌اید در نظر بگیرید و **فقط برچسب نقاط** S را از هر خروجی استخراج کنید. این برچسب‌ها را کنار خروجی‌های Single Link و Average Link که روی خود S اجرا شده‌اند بگذارید. برای هر چهار روش، نمایش مکانی سه‌بعدی یکسان باشد.

شرایط برابر

DBSCAN را با همان پارامترها دوباره روی S اجرا نکنید. چون S زیرمجموعهٔ کم‌تراکم‌تری از داده است، همان ε و `min_samples` ممکن است خوشه‌بندی کاملاً متفاوتی بسازند. این مقایسه برچسب‌های همان نقاط را کنار هم قرار می‌دهد، اما **شرایط آموزش هر چهار الگوریتم کاملاً برابر نیست:** دو روش روی کل داده و دو روش تنها روی S اجرا شده‌اند. این محدودیت را هنگام تفسیر نتیجه در نظر بگیرید.

برای هر روش، در یک جدول خلاصه **تعداد خوشه‌ها، اندازهٔ بزرگ‌ترین خوشه، میانهٔ اندازهٔ خوشه‌ها، تعداد خوشه‌های کمتر از ۲۰ عضو، درصد پوشش و امتیاز Silhouette (در صورت معتبر بودن)** را گزارش کنید؛ فهرست تک‌تک خوشه‌ها لازم نیست. برای روش‌هایی که همهٔ نقاط را برچسب می‌زنند پوشش ٪۱۰۰ است؛ در DBSCAN، اندازهٔ خوشه‌ها را بدون نویز حساب کنید و پوشش را سهم نقاط غیرنویز بگیرید. اگر پس از حذف نویز کمتر از دو خوشهٔ معتبر باقی ماند، Silhouette را «تعریف‌ناپذیر» گزارش کنید. نقشهٔ هر چهار روش را نیز با محدوده و مقیاس یکسان ارائه کنید.

برای بررسی توافق روش‌ها، **مقدار ARI را برای هر شش جفتِ این چهار خروجی** روی نقاط S محاسبه و در یک جدول گزارش کنید. در مقایسه‌های شامل DBSCAN، برچسب نویز را نیز یک گروه مجزا محسوب کنید؛ توجه کنید که این تصمیم بر تفسیر ARI اثر می‌گذارد. توافق زیاد بین روش‌ها لزوماً به معنای درست‌بودن خوشه‌بندی نیست.

در خروجی DBSCAN، **نویز را از محاسبهٔ Silhouette کنار بگذارید.** هنگام تفسیر این معیار، تفاوت تعداد خوشه‌ها و درصد پوشش روش‌ها را لحاظ کنید؛ امتیاز بالاتر لزوماً به معنای مناسب‌بودن بیشتر برای سناریوهای پروژه نیست.

پایداری در برابر نمونه‌گیری مجدد (Resampling Stability)

در این آزمایش کوتاه بررسی کنید که آیا با تغییر بخشی از نقاط ورودی، ساختار خوشه‌ها تقریباً حفظ می‌شود یا نه. این آزمایش **حساسیت به انتخاب نمونه** را می‌سنجد، نه حساسیت به مقداردهی اولیه.

۱. از نمونهٔ مشترک S (با ۲۰۰۰ نقطه)، **سه زیرمجموعهٔ تصادفی ۱۶۰۰تایی** (۸۰ درصدِ S) و **بدون جایگذاری** بسازید. برای نمونه‌گیری این سه زیرمجموعه به‌ترتیب از seedهای s، $s+1$ و $s+2$ استفاده کنید.

۲. فقط **سه روش** K-Means (با $k = 12$)، Single Link و Average Link (هر دو با برش در ۱۲ خوشه) را روی **هر سه زیرمجموعه** اجرا کنید. نمایش داده در همهٔ اجراها همان مختصات سه‌بعدی کرهٔ واحد باشد. برای K-Means، `n_init=10` و seed الگوریتم را در هر سه اجرا برابر s نگه دارید تا اثر تغییر نمونه با اثر مقداردهی اولیه مخلوط نشود.

۳. برای هر روش، سه جفت خروجی حاصل از سه زیرمجموعه را مقایسه کنید. **ARI هر جفت را فقط روی نقاط مشترک همان دو زیرمجموعه** محاسبه کنید؛ برچسب نقاط یکسان را براساس شناسهٔ اصلی آن‌ها کنار هم قرار دهید. نیازی به تطبیق شمارهٔ خوشه‌ها نیست.

۴. برای هر روش، **میانگین و دامنهٔ** سه مقدار ARI را گزارش کنید (دامنه = بیشینه منهای کمینه). در مجموع، این بخش **۹ اجرای خوشه‌بندی و ۹ محاسبهٔ زوجی ARI** دارد.

۵. با تکیه بر نتایج، توضیح دهید کدام روش **در همین آزمایش** پایدارتر بوده و چه ویژگی‌ای از سازوکار آن می‌تواند نتیجه را توضیح دهد. آیا پایداری بیشتر لزوماً به معنای خوشه‌بندی مناسب‌تر برای سناریوهای الف و ب است؟ چرا با فقط سه زیرمجموعه نباید دربارهٔ پایداری کلی الگوریتم‌ها نتیجهٔ قطعی گرفت؟

با یک نمونهٔ مشخص از خروجی‌ها نشان دهید چرا **بهترین امتیاز عددی لزوماً بهترین نتیجه برای سناریوی موردنظر نیست**.

پرسش ب

نتیجه‌گیری

جدول کوتاهی بسازید که برای هر پیش‌بینی P1 تا P4 مشخص کند **تأیید شده، رد شده یا هنوز شواهد کافی ندارد** و به نمودار یا عدد مربوط ارجاع دهد. سپس برای **هر سناریو** یک الگوریتم، نمایش داده و مجموعهٔ پارامتر پیشنهاد کنید. دلیل انتخاب خود را با **دو شاهد مشخص** و **یک محدودیت یا نقطه‌ضعف** بیان کنید. اگر یک الگوریتم برای هر دو سناریو انتخاب می‌کنید، توضیح دهید چرا.

یک نکته دربارهٔ تفسیر نتایج

این دیتاست برچسبِ «خوشهٔ درست» ندارد؛ بنابراین Purity و Rand Index برای سنجش صحت خوشه‌ها نسبت به حقیقت بیرونی در دسترس نیستند. معیارهایی مانند Silhouette نیز فقط بخشی از کیفیت خوشه‌بندی را اندازه می‌گیرند. پیشنهاد نهایی شما باید هم به **معیارهای عددی** و هم به **هدف کاربردی** تکیه کند.

بخش امتیازی

۱۰ نمره

دو پرسش زیر **اختیاری و مستقل از یکدیگر** هستند؛ هر پرسش ۵ نمره دارد و می‌توانید یک یا هر دو را انجام دهید. این بخش قرار است فهم عمیق‌تر شما را نشان دهد؛ **تحلیل و توجیه نتیجه** مهم‌تر از صرف اجرای الگوریتم است.

پرسش آ

تغییر کنترل‌شدهٔ مختصات — ۵ نمره

مقاومت در برابر تغییرات مکانی (Controlled Perturbation). فرض کنید مختصات ثبت‌شدهٔ بعضی زلزله‌ها اندکی خطا دارد. می‌خواهیم ببینیم این تغییرهای کوچک چه اثری بر خوشه‌بندی می‌گذارند. در این پرسش تنها K-Means و DBSCAN را بررسی کنید.

از **دادهٔ کامل زلزله‌ها**، به‌صورت تصادفی **۵ درصد نقاط** را با seed برابر $s+3$ انتخاب کنید. هر نقطهٔ انتخاب‌شده را در یک جهت تصادفی و به‌اندازهٔ تصادفی بین **۱۰ تا ۲۰ کیلومتر روی سطح زمین** جابه‌جا کنید. جابه‌جایی را به‌صورت جغرافیایی انجام دهید؛ افزودن مستقیم یک عدد ثابت به عرض یا طول جغرافیایی مجاز نیست. شناسه و ترتیب رکوردها را حفظ کنید و مختصات سایر نقاط را تغییر ندهید. روش و بذر تولید تغییرات را در Notebook ثبت کنید.

دو الگوریتم K-Means و DBSCAN را با **نمایش مکانی سه‌بعدی و دقیقاً همان پارامترهای منتخب قبلی**، یک بار روی دادهٔ اصلی و یک بار روی دادهٔ تغییریافته اجرا کنید. برای K-Means، seed الگوریتم نیز در دو اجرا یکسان باشد. **ARI** برچسب‌های قبل و بعد را روی همان رکوردها گزارش کنید؛ تعداد خوشه‌ها و اندازهٔ بزرگ‌ترین خوشه را مقایسه کنید و برای DBSCAN درصد نویز را نیز بنویسید.

بررسی کنید تغییر برچسب‌ها فقط به نقاط جابه‌جاشده محدود شده است یا نقاط جابه‌جانشده را هم تحت‌تأثیر قرار داده است؛ **تعداد نقاط با وضعیت یا عضویت خوشه‌ای تغییرکرده** را در هر دو گروه گزارش کنید. برای تشخیص تغییر عضویت، صرفاً شمارهٔ خام خوشه‌ها را مقایسه نکنید؛ چون شناسهٔ خوشه‌ها ممکن است عوض شود. دست‌کم یک نمونهٔ مشخص از تغییرات را روی نقشه یا با شواهد عددی توضیح دهید.

در پایان بگویید **در همین آزمایش** کدام روش مقاوم‌تر بوده است و چرا. آیا از یک تغییر تصادفی می‌توان دربارهٔ مقاومت کلی الگوریتم‌ها نتیجهٔ قطعی گرفت؟ آیا ARI بالا به‌تنهایی نشان می‌دهد که همهٔ نقاط جابه‌جاشده بدون تغییر مانده‌اند؟

پرسش ب

HDBSCAN — ۵ نمره

در فاز ۳ دیدید که انتخاب یک مقدار ثابت برای ε در DBSCAN ممکن است برای مناطق متراکم و کم‌تراکم به یک اندازه مناسب نباشد. HDBSCAN را به‌اختصار مطالعه کنید و با زبان خود توضیح دهید این روش چه تفاوتی با DBSCAN دارد.

هر دو الگوریتم را روی **همان نمونهٔ مشترک** S و با **ویژگی‌های مکانی یکسان** اجرا کنید. پارامترهای انتخابی هر روش را گزارش و توجیه کنید. **پارامترهای DBSCAN فاز ۳ را بدون بررسی روی** S **به کار نبرید.** چگالی نمونهٔ S کمتر از دادهٔ کامل است؛ بنابراین پارامترها، به‌ویژه ε، را برای همین نمونه دوباره تنظیم کنید (مثلاً

با بررسی فاصله تا دهمین همسایه در S).

برای هر دو روش، تعداد خوشه‌ها، درصد نویز کل و نقشهٔ نتایج را ارائه دهید. سپس برای هر یک از سه ناحیه‌ای که در فاز ۱ انتخاب کرده‌اید، درصد نویز آن ناحیه را در هر دو روش گزارش کنید. تعداد زلزله‌های هر ناحیه در S را هم کنار درصدها بنویسید.

آیا HDBSCAN در این مثال واقعاً بهتر عمل کرده است؟ پاسخ را با توجه به هدف **سناریوی ب** بدهید. توجه کنید که **نویز کمتر به‌تنهایی نشانهٔ خوشه‌بندی بهتر نیست**. مشخص کنید چه مصالحه‌ای را می‌پذیرید؛ مثلاً حفظ ساختارهای کم‌تراکم در برابر نویز شدن بخشی از ساختارهای متراکم. دست‌کم یک محدودیت یا هزینهٔ روش جدید را توضیح دهید. **بهتر بودن HDBSCAN را از قبل فرض نکنید.**

بارم‌بندی

بخش	نمره
فاز ۱: شناخت داده و پیش‌بینی	۲۰
فاز ۲: K-Means	۲۵
فاز ۳: DBSCAN و سلسله‌مراتبی	۳۰
فاز ۴: ارزیابی و نتیجه‌گیری	۲۵
مجموع	**۱۰۰**
پرسش امتیازی آ: Controlled Perturbation	۵
پرسش امتیازی ب: HDBSCAN	۵
مجموع امتیازی	**۱۰**
مجموع با نمرهٔ امتیازی	**۱۱۰**

جدول ۱: بارم‌بندی پروژه

موفق باشید